

BLM22535 – Makine Öğrenmesi Dersi Final Sunumu

Sunum Tarihi: 24.12.2025 – 09:00 – T-H109

1) Problem Tanımı ve Motivasyon

a. Neden bu problem seçildi? Motivasyon nedir?

- Bu problem, görüntü tabanlı sınıflandırma alanında hem **teorik bilgilerin** hem de **pratik uygulamaların** birlikte kullanılmasına olanak sağladığı için seçilmiştir. Satranç taşları; şekil, renk, doku ve boyut açısından birbirine benzeyen ancak detaylı incelendiğinde ayırt edici özellikler barındıran nesnelerdir. Ayrıca farklı satranç setlerinde taşların tasarımları değişiklik gösterebilmekte, bu durum görsel varyasyonu artırmaktadır.

Bu çeşitlilik, makine öğrenmesi modellerinin genelleme yeteneğini test etmek için uygun ve gerçekçi bir problem sunmaktadır. Görüntü sınıflandırma problemleri, günümüzde bilgisayarla görü, otonom sistemler ve akıllı analiz uygulamalarında yaygın olarak kullanılmaktadır. Bu nedenle satranç taşı tanıma problemi, hem akademik hem de uygulamalı açıdan anlamlı bir çalışma alanı oluşturmaktadır.

Bu çalışmanın motivasyonu; görüntü işleme ve makine öğrenmesi tekniklerini kullanarak, farklı açılardan çekilmiş satranç taşı görüntülerinden taşın türünü ve rengini otomatik olarak tespit edebilen bir sistem geliştirmek ve farklı öğrenme yaklaşımlarının performanslarını karşılaştırmaktır.

b. Seçilen problem sınıflandırma, regresyon ve kümeleme problemi mi?

- Bu projede ele alınan problem, **çok sınıflı bir sınıflandırma problemidir**. Modelin görevi, verilen bir satranç taşı görüntüsünü önceden tanımlanmış sınıflardan birine atamaktır.

Her bir görüntü:

- Taşın **türü** (Şah, Vezir, Kale, Fil, At, Piyon)
- Taşın **rengi** (Beyaz veya Siyah)

bilgilerini içeren etiketlere sahiptir. Bu nedenle problem, sayısal bir değer tahmini gerektiren regresyon problemi veya etiketsiz veri üzerinden yapı keşfi yapan kümeleme problemi değildir. Aksine, etiketli veri kullanılarak gerçekleştirilen denetimli (supervised) bir sınıflandırma problemidir.

c. Bu çalışmanın amacı ve hedeflenen çıktı(lar) nedir?

- Bu çalışmanın temel amacı, satranç tahtası üzerinde bulunan taşların görüntülerinden yararlanarak, taşın türünü ve rengini doğru bir şekilde sınıflandırabilen bir makine öğrenmesi modeli geliştirmektir.

Bu kapsamda hedeflenen çıktılar şunlardır:

- Satranç taşı görüntülerini otomatik olarak sınıflandırabilen bir sistem geliştirilmesi

- Geleneksel makine öğrenmesi yöntemi (Decision Tree) ile derin öğrenme tabanlı yöntemin (CNN) performanslarının karşılaştırılması
- Modellerin doğruluk, F1-skoru ve karmaşıklık matrisi gibi metriklerle değerlendirilmesi
- Görüntü ön işleme ve veri çoğaltma tekniklerinin model performansına etkisinin analiz edilmesi

Sonuç olarak, bu çalışmada farklı makine öğrenmesi yaklaşımlarının görüntü sınıflandırma problemlerindeki etkinliğinin ortaya konulması ve elde edilen bulguların karşılaştırmalı olarak yorumlanması hedeflenmektedir.

2) Makine Öğrenmesi Yöntemleri

- Probleme uygun olarak seçilen makine öğrenme yöntemleri.
 - Bu projede, satranç taşı görüntülerinin sınıflandırılması problemi için iki farklı makine öğrenmesi yaklaşımı kullanılmıştır:
 - **Ağaç tabanlı yöntem:** Decision Tree
 - **Derin öğrenme tabanlı yöntem:** Convolutional Neural Network (CNN)
 Bu iki yöntem, geleneksel makine öğrenmesi ile derin öğrenme yaklaşımlarını karşılaştırmak amacıyla seçilmiştir.
- Bu yöntemlerin seçilme nedenleri.
 - Decision Tree algoritması, basit yapısı ve yorumlanabilirliği sayesinde temel bir karşılaştırma modeli olarak tercih edilmiştir. Görüntü verisi üzerinde sınırlı performans göstermesine rağmen, hızlı eğitilmesi ve kolay uygulanması önemli avantajlar sunmaktadır.
 - CNN modeli ise görüntü sınıflandırma problemlerinde yaygın olarak kullanılan ve yüksek başarı oranları elde eden bir derin öğrenme yöntemidir. Görüntülerden otomatik olarak özellik çıkarabilmesi, bu problem için uygun bir çözüm olmasını sağlamıştır.
- Yöntemlerin avantaj ve dezavantajlarının karşılaştırılması.
 - **Decision Tree:**
 - Avantajları: Hızlı eğitim süresi, basit yapı, yorumlanabilir sonuçlar
 - Dezavantajları: Görüntü gibi yüksek boyutlu verilerde düşük performans, aşırı öğrenmeye yatkınlık
 - **CNN:**
 - Avantajları: Yüksek doğruluk oranı, karmaşık görsel özellikleri öğrenebilme, güçlü genelleme yeteneği
 - Dezavantajları: Uzun eğitim süresi, yüksek hesaplama maliyeti, daha fazla veri ihtiyacı
- Yöntemlerin implementasyonu

- Decision Tree modeli, görüntülerden elde edilen temel özellikler kullanılarak eğitilmiştir. Model, eğitim veri kümesi üzerinde oluşturulmuş ve test verisi ile değerlendirilmiştir.

CNN modeli ise evrişim (convolution), aktivasyon ve pooling katmanlarından oluşan bir mimari ile tasarlanmıştır. Görüntüler ön işleme adımlarından geçirildikten sonra model eğitilmiş ve doğrulama veri kümesi ile performansı izlenmiştir.

e. Hiper-parametre optimizasyonu

- Modeller için ayarlanabilir hiper-parametreler şunlardır:

- **Decision Tree:**

- Maksimum ağaç derinliği
- Bölünme kriteri
- Minimum örnek sayısı

- **CNN:**

- Öğrenme oranı (learning rate)
- Batch size
- Epoch sayısı
- Katman sayısı ve filtre boyutları

Bu hiper-parametreler deneysel olarak belirlenmiş ve model performansına etkileri gözlemlenmiştir.

3) Deneysel Çalışmalar

a. Veri kümesi açıklanmalı.

i. Veri kümesindeki örnekler hangi kaynaklardan ve nasıl toplandı?

- Bu çalışmada kullanılan veri kümesi, açık kaynaklı satranç taşı görüntü veri setlerinden ve çevrim içi görsel kaynaklardan elde edilmiştir.

Görseller, farklı satranç setlerine ait olacak şekilde seçilmiş ve farklı çekim açıları, arka planlar ve ışık koşullarını içermesine dikkat edilmiştir. Toplanan görüntüler manuel olarak sınıflandırılmış ve her bir görüntü, taşın türü ve rengine göre etiketlenerek veri kümesine dahil edilmiştir.

ii. Kaç tane sınıf, her bir sınıftan kaç örnek

- Oluşturulan veri kümesi, satranç taşlarının türü ve rengi dikkate alınarak toplam **12 farklı sınıftan** oluşmaktadır. Bu sınıflar; altı farklı taş türünün (Şah, Vezir, Kale, Fil, At ve Piyon) her biri için **Beyaz** ve **Siyah** renk olacak şekilde etiketlenmiştir. Her bir sınıf için yaklaşık olarak benzer sayıda görüntü bulunacak şekilde veri kümesi dengeli olarak oluşturulmuştur. Bu denge, modelin tüm sınıfları eşit şekilde öğrenebilmesini sağlamak amacıyla gözetilmiştir.

iii. Train/test/val kümeleri:

-Veri kümesi, modelin eğitimi ve değerlendirilmesi amacıyla rastgele olarak üç alt kümeye ayrılmıştır. Bölünme oranları %70 eğitim, %15

doğrulama ve %15 test olacak şekilde belirlenmiştir. Eğitim kümesi modelin öğrenmesi için, doğrulama kümesi eğitim sırasında performans takibi ve hiper-parametre ayarlamaları için, test kümesi ise modelin daha önce görmediği veriler üzerindeki nihai performansını ölçmek için kullanılmıştır.

- b. Veri kümesi için hangi ön-işleme (pre-processing) adımları uygulandı? Bu adımlar açıklanmalı.
 - Model eğitimi öncesinde tüm görüntüler belirli bir boyuta yeniden ölçeklendirilmiş ve piksel değerleri normalize edilmiştir. Bu sayede tüm görüntülerin aynı giriş formatına sahip olması sağlanmış ve modelin daha kararlı bir şekilde öğrenmesi hedeflenmiştir. Ayrıca, gereksiz gürültülerin etkisini azaltmak ve eğitim sürecini hızlandırmak amacıyla temel görüntü düzenleme işlemleri uygulanmıştır.
- c. Seçilen yöntemlerin performanslarının değerlendirilmesi için uygun olarak seçilen değerlendirme metriklerinin ne olduğu ve nasıl hesaplandığı açıklanmalı.
 - Modellerin performansını değerlendirmek için **Accuracy**, **Confusion Matrix** ve **F1-skoru** metrikleri kullanılmıştır. Accuracy, doğru sınıflandırılan örneklerin toplam örnek sayısına oranı olarak hesaplanmış ve genel başarıyı göstermiştir. Confusion Matrix, her bir sınıf için doğru ve yanlış tahminlerin dağılımını görselleştirerek modelin hangi sınıflarda hata yaptığını analiz etmeye imkân tanımıştır. F1-skoru ise precision ve recall değerlerinin harmonik ortalaması olarak hesaplanmış olup, özellikle sınıflar arası dengenin değerlendirilmesinde kullanılmıştır.
- d. Seçilen yöntemlerin eğitilmesi için uygulanan adımlar ve kullanılan hiper-parametreler
 - Seçilen modeller, eğitim veri kümesi kullanılarak eğitilmiştir. Eğitim sürecinde görüntüler ön işleme adımlarından geçirilmiş ve modele giriş olarak verilmiştir. CNN modeli için eğitim sırasında **learning rate**, **batch size** ve **epoch sayısı** gibi temel hiper-parametreler belirlenmiştir. Learning rate, modelin ağırlık güncellemelerinin hızını kontrol etmek amacıyla; batch size, her adımda kullanılan örnek sayısını belirlemek amacıyla; epoch sayısı ise modelin veri kümesini kaç kez göreceğini belirlemek için kullanılmıştır. Decision Tree modeli için ise ağacın karmaşıklığını kontrol etmek amacıyla maksimum derinlik ve bölünme kriterleri gibi hiper-parametreler ayarlanmıştır. Bu parametreler deneysel olarak belirlenmiş ve model performansına etkileri gözlemlenmiştir.
- e. Veri çoğaltma adımları uygulandı mı?
 - Evet, veri kümesinin sınırlı olması nedeniyle eğitim veri kümesi üzerinde veri çoğaltma (data augmentation) adımları uygulanmıştır. Bu kapsamda görüntüler üzerinde döndürme, yatay ve dikey çevirme ile ölçekleme işlemleri

gerçekleştirilmiştir. Uygulanan bu adımlar sayesinde veri çeşitliliği artırılmış ve modelin farklı açılar ve görsel varyasyonlara karşı daha dayanıklı hale gelmesi sağlanmıştır.

- f. Seçilen yöntemler üzerinde hiper-parametre optimizasyonu uygulandı mı?
- Bu çalışmada hiper-parametre optimizasyonu, kapsamlı otomatik yöntemler (Grid Search veya Random Search gibi) yerine **deneysel ve manuel ayarlamalar** yoluyla gerçekleştirilmiştir. Modellerin performansı göz önünde bulundurularak farklı hiper-parametre değerleri denenmiş ve en iyi sonuç veren yapı tercih edilmiştir.

CNN modeli için öğrenme oranı (learning rate), batch size ve epoch sayısı gibi hiper-parametreler farklı değerler ile test edilmiştir. Bu değerler, doğrulama veri kümesi üzerindeki performans gözlemlenerek seçilmiştir. Decision Tree modeli için ise maksimum ağaç derinliği ve bölünme kriterleri gibi parametreler değiştirilerek modelin aşırı öğrenme eğilimi kontrol altına alınmıştır.

Uygulanan bu yaklaşım sayesinde modellerin performansı iyileştirilmiş ve daha dengeli sonuçlar elde edilmiştir.

4) Sonuç ve Tartışma

-Bu çalışmada, satranç taşı görüntülerinin sınıflandırılması problemi için iki farklı makine öğrenmesi yaklaşımı kullanılmış ve elde edilen sonuçlar karşılaştırmalı olarak değerlendirilmiştir. Kullanılan yöntemler arasında **Decision Tree** ve **Convolutional Neural Network (CNN)** modelleri yer almaktadır.

-Elde edilen deneysel sonuçlar, CNN tabanlı modelin Decision Tree modeline kıyasla daha yüksek doğruluk ve F1-skoru değerleri elde ettiğini göstermiştir. CNN modeli, görüntülerdeki karmaşık şekil, doku ve kenar bilgilerini otomatik olarak öğrenebildiği için özellikle benzer görünüme sahip satranç taşlarının ayırımında daha başarılı olmuştur. Decision Tree modeli ise basit yapısı nedeniyle görüntü verilerindeki yüksek boyutluluğu yeterince temsil edememiştir.

-Veri ön işleme ve veri çoğaltma adımlarının uygulanması, her iki modelin performansını olumlu yönde etkilemiştir. Özellikle veri çoğaltma teknikleri sayesinde CNN modelinin genelleme yeteneği artmış ve aşırı öğrenme eğilimi azaltılmıştır. Validation kümesi kullanılarak yapılan hiper-parametre ayarlamaları da model performansının dengelenmesine katkı sağlamıştır.


-Sonuçlar genel olarak değerlendirildiğinde:

-CNN modellerinin görüntü sınıflandırma problemlerinde daha etkili olduğu,

-Geleneksel makine öğrenmesi yöntemlerinin karşılaştırma ve temel analiz amacıyla faydalı olduğu,

-Veri ön işleme ve veri çoğaltma adımlarının model başarısında kritik rol oynadığı gözlemlenmiştir.

-Bu çalışma, derin öğrenme tabanlı yöntemlerin görüntü sınıflandırma problemlerinde neden yaygın olarak tercih edildiğini açık bir şekilde ortaya koymaktadır.



(Şekil 1)

Şekil 1’de, satranç taşı sınıflandırma problemi için kullanılan Decision Tree ve CNN modellerinin doğruluk (accuracy) değerleri karşılaştırılmaktadır. CNN modelinin, görüntü verileri üzerinde Decision Tree modeline kıyasla daha yüksek doğruluk elde ettiği gözlemlenmiştir.